

**Akademia Górniczo-Hutnicza im Stanisława Staszica
Wydział Automatyki, Elektroniki Informatyki i Inżynierii
Biomedycznej**



Techniki Obrazowania Medycznego

Prototyp realizacji projektu

**Krystian Strzałka, Jakub Chabior, Katarzyna Urbanek, Aleksandra Augustyn
Kraków, 22 czerwca 2020**

Spis treści

1	Cel	2
2	Wstęp	2
3	Struktura kodu	4
4	Wyniki	7
5	Dyskusja oraz podsumowanie	9
6	Podział zadań	10

1 Cel

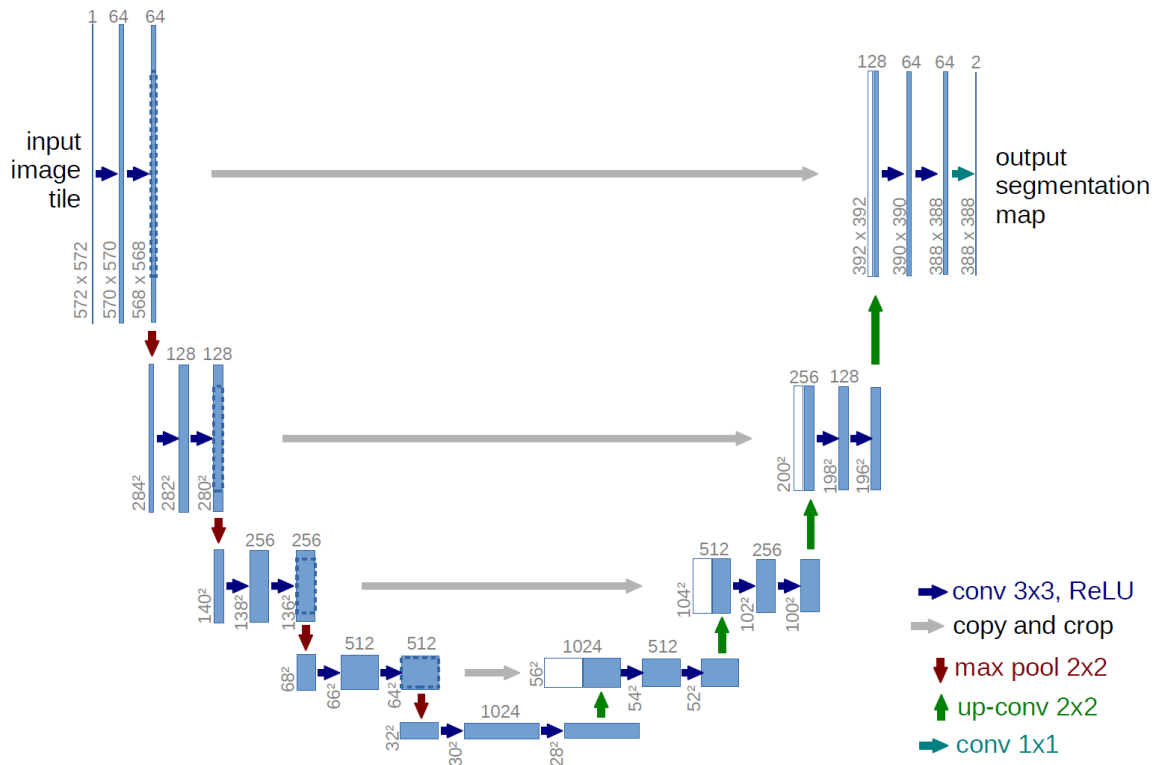
Celem projektu było opracowanie rozwiązania jednego z problemów zaprezentowanych na konferencji naukowej MICCAI 2019. Należało zaimplementować automatyczną metodę segmentacji nerek i nowotworów nerek na obrazach tomografii komputerowej oraz zaproponować sposób ewaluacji uzyskanych wyników.

2 Wstęp

Nowotwór nerki jest coraz częściej występującą chorobą, której późne wykrycie najczęściej prowadzi do śmierci pacjenta. Do obecnie stosowanych metod leczenia należy nefrektomia radykalna, która polega na całkowitym wycięciu guza wraz z nerką oraz otaczającą tkanką tłuszczową. Jednak postęp medycyny oraz dokładność obrazowania coraz częściej umożliwiają przeprowadzenie częściowej nefrektomii, która polega na wycięciu guza, ale pozostawienie nerki. Bardzo ważną rolę w diagnostyce nowotworów guza gra odpowiednia segmentacja nerek oraz guzów na obrazach tomografii komputerowej (CT). Obecnie segmentacja jest wykonywana ręcznie przez specjalistów, jednak taka metoda generuje wiele niedokładności oraz w znacznym stopniu zależy od doświadczenia osoby wykonującej segmentację. W celu usprawnienia oraz zwiększenia dokładności tego procesu, niezbędna jest automatyzacja.

Segmentacja obrazów polega na wykonaniu podziału na regiony o zbliżonych właściwości na podstawie poziomu szarości, koloru, tekstury, kontrastu czy jasności. Wykonuje się ją w celu określenia budowy anatomicznej, zlokalizowania nieprawidłowości (jak na przykład nowotwory) oraz określenia rozmiarów danej tkanki (przykładowo w celu określenia przyrostu rozmiaru guza). Segmentację obrazów CT można wykonać między innymi poprzez dobór progu na podstawie histogramu, grupowanie obszarów na podstawie ich cech, metodami obszarowymi lub krawędziowymi. Bardzo obiecującą metodą jest uczenie sieci neuronowych, które analizując obszary obrazu są w stanie rozpoznawać pewne nieskomplikowane zależności jak krawędzie. [1]

Sieć konwolucyjna U-Net (Rysunek 1) została stworzona właśnie do rozpoznawania krawędzi na obrazach biomedycznych. U-Net składa się z dwóch podstruktur - kodera (encoder) oraz dekodera (decoder). Pierwsza część ma na celu uchwycenie kontekstu na obrazie poprzez zmniejszanie odbieranych pól w trakcie przechodzenia przez warstwy, natomiast dekodery jest nazywany ścieżką symetrycznego rozrastania i ma na celu określanie precyzyjnej lokalizacji wykorzystując transponowane sploty. Sieć taka może przyjmować za dane wejściowe obraz o dowolnym rozmiarze, zwracając obraz o zbliżonej wielkości. [2]



Rysunek 1. Architektura sieci U-Net [3]

Podczas uczenia się sieci neuronowej, bardzo ważne jest zastosowanie normalizacji w celu przyspieszenia procesu, zwiększenia dokładności oraz zminimalizowania błędów. Jednym z takich błędów jest wewnętrzna zmiana współzmiennnej (internal covariate shift), czyli zmiana parametrów sieci w trakcie uczenia się. W celu eliminacji tego błędu, najczęściej stosowane jest Batch Normalization po każdej warstwie konwolucyjnej. Normalizacja ta polega na ponownym centrowaniu i skalowaniu warstwy. Innymi typami normalizacji stosowanymi do eliminacji wewnętrznej zmiany współzmiennnej jest Instance Normalization oraz Layer Normalization. [4]

3 Struktura kodu

W tabeli 1 przedstawiono spis plików zamieszczonych w repozytorium oraz opis i działanie funkcji, które się w nich zawierają. Na rysunku 2 przedstawiono diagram modelu sieci wykorzystanej w projekcie do segmentacji.

Tabela 1


Opis plików w repozytorium

Nazwa	Opis
preprocessing.py	Przygotowanie obrazów CT do dalszej obróbki.
scale	Skalowanie obrazu od 0 do 1 poprzez odjęcie minimum i podzielenie przez 4095, czyli maksymalną wartość skanów.
find segmentation	Następuje dodanie do siebie kolejnych <i>slice</i> , w momencie, gdy suma wartości któregoś jest większa od 0, to funkcja zwraca indeks początku segmentacji, podobny proces przebiega także od końca segmentacji skanu aby uzyskać indeks końca segmentacji.
preprocess X	Obiekt <i>niftyImage</i> zamieniany jest na <i>numpy array</i> , następnie skalowany za pomocą funkcji <i>scale</i> . Następuje dodanie dodatkowego wymiaru aby był on tam gdzie jest <i>channel</i> . W przypadku jeśli drugi albo trzeci wymiar jest inny niż 512x512 to zostaje przeskalowany do 512x512.
preprocess Y	Również działa na obiekcie <i>niftyImage</i> i zamienia go na <i>numpy array</i> . Znajduje początek i koniec segmentacji funkcją <i>find segmentation</i> , a następnie zamienia na dane kategoryczne. Ewentualnie skalowanie i zwraca, <i>numpy array y</i> , a także początek oraz koniec fragmentu, w którym znajduje się nerka.
dataGenerator.py	Skrypt korzysta z danych zwróconych przez <i>preprocessing.py</i> , zawiera generatory, które przekazują sieci odpowiednie wartości danych.
trainGenerator	Iteruje po <i>case</i> listy treningowej, wybiera fragmenty, w których znajdują się nerki, zwraca fragmenty o rozmiarach [batch size, 512, 512, 1] dla X i [batch size, 512, 512, 3] dla y.
validation generator	Działanie identyczne jak w przypadku <i>trainGenerator</i> , dodatkowo wypisuje informacyjny tekst "validation in progress".
NeuralNetowrk.py	Skrypt zawierający architekturę modelu.
makeModel	Funkcja zwracająca gotowy model.
training.py	Wczytanie modułów, tworzenie instancji modelu. Pozwala na wizualizację jakości modelu podczas nauki. Wytwarza się lista z numerami <i>case</i> 'ów do uczenia oraz walidacji.
predict.py	Skrypt wczytuje zadany <i>case</i> oraz wyświetla okienko <i>matplotlib</i> ze poziomym suwakiem i trzema obrazami - wejściowym, <i>ground truth segmentation</i> oraz <i>our segmentation</i> . W celu wyświetlenia wyniku <i>case</i> o danym numerze należy wpisać w konsoli na przykład „python predict.py 1” dla przypadku 1. Wymagany jest folder <i>data</i> z repozytorium <i>kits19</i> w tym samym folderze co skrypt. Możliwe jest zapisanie segmentacji w formacie <i>.nii</i> poprzez podanie dowolnego drugiego argumentu w postaci liczby całkowitej.




4 Wyniki


Model jest w stanie prawidłowo rozpoznać nerki, lecz wyłącznie w niektórych przypadkach jest w stanie określić dokładne położenie komórek nowotworowych. Podczas trenowania ewaluowano model przy pomocy dokładności oraz współczynnika Dice'a. Wyniki przedstawiono na rysunkach 3, 4 oraz 5.



Rysunek 3. Dokładność zbioru treningowego oraz walidacyjnego



Rysunek 4. Współczynnik Dice'a zbioru treningowego oraz walidacyjnego




Rysunek 5. Funkcja kosztu bazowana na współczynniku Dice'a dla zbioru treningowego oraz walidacyjnego

Tabela 2


Wartości ewaluacji dla modelu (epoka 18)

	Dokładność	Dice	Dice koszt.
Zbiór treningowy	0.9948	0.9968	0.003177
Zbiór walidacyjny	0.9884	0.9926	0.007071


Poniżej umieszczono porównanie rzeczywistego oraz przewidzianego położenia nowotworu dla wybranych przypadków.



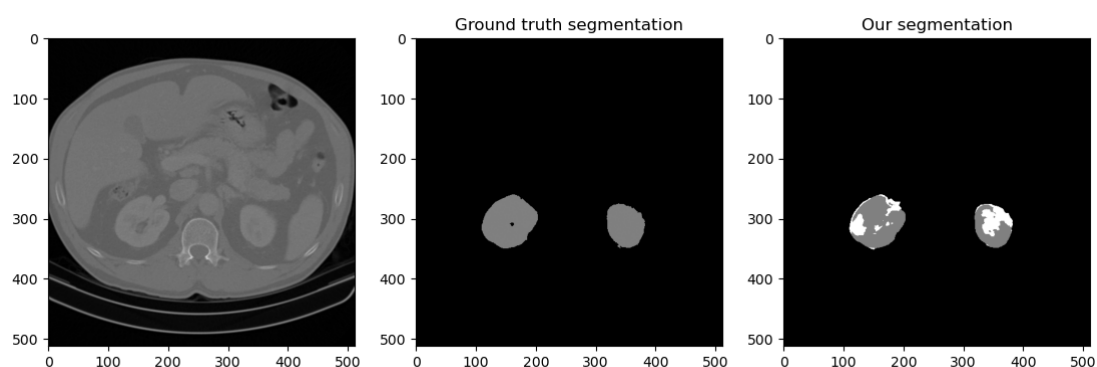
Rysunek 6. Predykcja położenia nowotworu w przypadku nr 55




Rysunek 7. Predykcja położenia nowotworu w przypadku nr 209



Rysunek 8. Predykcja położenia nowotworu w przypadku nr 205




Rysunek 9. Predykcja położenia nowotworu w przypadku nr 190



Rysunek 10. Predykcja położenia nowotworu w przypadku nr 123

5 Dyskusja oraz podsumowanie

Stworzony model nie daje przewidywalnych wyników, dla niektórych przypadków zwraca dokładną segmentację nowotworu, natomiast dla innych generuje błędne wyniki prawdopodobnie przez zbyt dużą czułość. Oznacza to, że model nadal wymaga dopracowania oraz pewnych korekcji.



Rysunek 11. Wolumetryczne przedstawienie, wygenerowanej segmentacji. Po lewej segmentacja wykonana przez lekarza a po prawej segmentacja wykonana przez model. Łatwo zauważyć że model jest zbyt czuły jeśli chodzi o zmiany nowotworowe lecz prawidłowo segmentuje sam narząd.

Na podstawie załączonych przykładowych predykcji położenia nowotworu widać, że w przypadku numer 55, 209 oraz 205 nasza segmentacja była dokładna. Natomiast w zdjęciu z przypadku 190 nowotwór został oznaczony mimo jego braku, a w przypadku numer 123 w ogóle nie doszło do segmentacji nerki.

6 Podział zadań

Augustyn Aleksandra - dokumentacja, pomoc przy researchu

Chabior Jakub - pomoc w pisaniu kodu i rozwiązywaniu problemów

Strzałka Krystian - pisanie kodu, trenowanie sieci, opracowanie architektury programu, wizualizacje i grafy do dokumentacji

Urbanek Katarzyna - research, pomoc przy ewaluacji

Literatura

- [1] Sharma N, Aggarwal LM. Zautomatyzowane techniki segmentacji obrazów medycznych. J Med Phys. 2010.
- [2] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In Nassir Navab, Joachim Hornegger, William M. Wells, and Alejandro F. Frangi, editors, *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, pages 234–241, Cham, 2015. Springer International Publishing. ISBN 978-3-319-24574-4.
- [3] <https://lmb.informatik.uni-freiburg.de/people/ronneber/u-net/>.
- [4] Xiao-Yun Zhou and Guang-Zhong Yang. Normalization in training u-net for 2d biomedical semantic segmentation, 2018.
- [5] Nicholas Heller, Niranjana Sathianathan, Arveen Kalapara, Edward Walczak, Keenan Moore, Heather Kaluzniak, Joel Rosenberg, Paul Blake, Zachary Rengel, Makinna Oestreich, Joshua Dean, Michael Tradewell, Aneri Shah, Resha Tejpaul, Zachary Edgerton, Matthew Peterson, Shaneabbas Raza, Subodh Regmi, Nikolaos Papanikolopoulos, and Christopher Weight. The kits19 challenge data: 300 kidney tumor cases with clinical context, ct semantic segmentations, and surgical outcomes, 2019.